


신경망 노드 가지치기를 위한 유전 알고리즘(NNPGA) 논문 정리

("신경망의 노드 가지치기를 위한 유전 알고리즘에 대해 발표하겠습니다.")

요약(Abstract)

이 논문은 신경망의 최적화 기법인 가지치기에 유전 알고리즘을 적용하는 접근법을 제시.

("이 논문에서는 신경망의 최적화 기법중 하나인 가지치기에 유전알고리즘을 적용하는 접근법을 제시했는데요, 일단 신경망과 가지치기에 대해 짧게 설명하고 넘어가겠습니다.")



("이 그림 많이들 보셨을텐데 신경망이란 입력층, 은닉층, 출력층의 노드들이 서로 뉴런처럼 연결되어 있는 구조를 뜻하고 각 연결에서의 가중치들이 학습 과정에서 입력데이터가 정답 데이터를 표현할 수 있는 방향으로 조정됩니다.")


가지치기(pruning): 큰 신경망에서 필요 없는 노드나 연결을 제거하는 과정



("가지치기는 큰 구조의 신경망에서 필요 없는 노드나 연결을 제거하는 과정인데 마치 나무의 불필요한 가지를 잘라내어 더 건강하게 만드는 것과 같다고 보시면 됩니다. 이러한 가지치기 방법을 신경망에서 최적화 기법으로 사용하고, 얼마나 가지를 쳐낼것인가를 유전알고리즘으로 보겠다는게 이 연구의 방향입니다.")

신경망은 종종 필요 이상으로 복잡한 구조를 가져 과적합과 계산 비효율성을 초래하는데 이 연구는 유전알고리즘을 통해 신경망의 구조를 최적화하면서도 성능을 유지하거나 향상시키는 방법을 제안함.

("여기서 과적합이란 모델이 테스트 데이터를 너무 잘 맞춰서 새 데이터에 맞추지 못하는, 일반화 성능이 저하되는 현상을 말합니다. 이런 과적합을 피하기 위해 테스트 데이터를 적당히 맞추자, 가지치기로 노드를 적당히 끊어 성능을 일반화시키자 이런 말입니다.")



("사진에서 보면 모델이 테스트 데이터를 너무 잘 맞춰 버릴때 만약 노란색 데이터가 자신과 비슷한 특성을 가진 데이터 근처에 들어왔음에도 분류를 하지 못하는 상황이 발생할 수 있습니다. 또한 회귀 문제에서도 분명 테스트 데이터와 비슷한 특성을 가진 데이터가 들어왔음에도 큰 오류가 발생하는 상황이 과적합입니다.")

이 연구는 기존 연구들과 달리 **입력층과 은닉층 노드를 하나의 염색체로 표현하여 동시에 최적화**하는 방법을 제안하며, 자식 네트워크가 부모로부터 가중치를 상속받는 특징이 있음.

("이 연구에서는 입력층과 은닉층을 별도로 최적화하는 기존 연구들과 달리 입력층과 은닉층 노드를 하나의 염색체로 표현해서 동시의 최적화하는 방법을 제안했고, 자식 신경망이 부모 신경망의 가중치를 상속받는다는 특징이 있습니다.")

UCI Machine Learning Repository의 다양한 데이터셋으로 실험한 결과, 신경망 노드 **가지치기 비율이 약 8%~25%일 때 최적의 성능**을 보였으며, 다른 가지치기 및 구조 증가 알고리즘과 비교했을 때 우수한 성능을 나타냄.

("다양한 데이터셋으로 실험했을때 노드를 약 4분의 1정도 쳐내도 좋은 성능을 보인다. 다른 실험들과 비교했을때도 괜찮다라는 결과가 나왔다고 합니다.")


1. 서론

신경망의 성능은 구조(입력 및 은닉 노드 수)와 가중치, 훈련 계수 등 다양한 요소에 의해 좌우됨
최적화된 구조와 가중치를 갖는 신경망은 일반화 성능이 뛰어나지만, 최적의 구조를 찾는 것은 많은 시간과 노력이 필요.
Why? 신경망을 설명할 수 있는 방법이 없음.


("신경망의 성능은 구조와 가중치 등 다양한 요소에 영향을 받는데 이 구조를 찾는 것이 매우 힘들다고 합니다. 그럴 수 밖에 없는게 이 신경망을 우리는 설명할 수 있는 방법이 없기 때문에 오로지 설계자의 경험이나 시행착오에 의존할 수 밖에 없습니다.")

구조 최적화 방법으로는 크게 구조 증가(constructive) 방법과 가지치기(pruning) 방법이 있음.

("기존 구조 최적화 방법에는 크게 구조 증가와 가지치기가 주로 사용되었는데 먼저 구조 증가는 말 그대로 노드를 늘리거나 노드간 연결을 더 해서 좀 더 복잡한 패턴을 학습시키자 이고,



가지치기는 전에 말했듯이 좀 테스트 데이터를 덜 맞추고 성능을 일반화 시키자는 방법입니다.")



본 논문에서는 신경망의 노드 가지치기를 위한 유전 알고리즘을 제안하며, 입력층과 은닉층이 상호 연관되어 있다는 점에 착안하여 두 층의 노드를 하나의 염색체로 표현하여 동시에 최적화하는 방법을 시도함.

특히 유전 알고리즘 연산 과정에서 생성되는 신경망은 부모의 가중치를 상속받아 학습 효율성을 높임.

("본 논문에서는 신경망의 구조 증가보다는 가지치기를 얼마나 할 것인가를 유전알고리즘으로 정하고, 입력층과 은닉층을 하나의 염색체로 표현해 동시에 최적화 하는 방법을 시도했고, 추가로 연산 과정에서 생성되는 신경망. 즉 자식 신경망은 부모의 가중치를 상속받아 학습 효율성을 높이는 방법을 제시했습니다.")

2. 관련 연구

신경망 최적화는 일반화 능력이 뛰어난 구조와 가중치를 찾는 작업.

일반화 성능이 좋은 신경망을 찾기 위해, 보통 신경 망의 구조를 여러 가지로 변경하며 성능 실험을 하여 그중 가장 좋은 것을 답으로 취함.

적절한 네트워크 구조를 사전에 알기 어렵고 휴리스틱 방법은 많은 시간이 소요되는 문제가 있어, 이를 해결하기 위해 구조 증가 및 가지치기(Pruning) 알고리즘이 사용됨.

("신경망을 어떻게 가볍고 효율적으로 만들 수 있을까. 앞에서 말했듯이 신경망을 설명할 수 있는 방법이 없기 때문에 구조에 정답은 없습니다. 다만 좀 더 좋은 성능을 내기 위해 여러 구조를 테스트해보며 경험을 쌓고, 시행착오를 겪는 과정에서 보다 좋은 구조를 발견해 내는 것입니다.")

신경망 가지치기 방법에는 크게 민감도 방법, 정규화/패널티 방법, 유전 알고리즘 이용 방법이 있으며, 유전 알고리즘을 이용한 최적화는 다시 **가중치 최적화**, **구조 최적화**, **가중치와 구조 동시 최적화**로 나눌 수 있습니다.

("신경망의 가지치기 방법은 민감도 방법, 패널티, 유전알고리즘 방법이 있는데 민감도와 패널티 방법은 매개변수에 성능이 좌우되어 지역 최적해에 쉽게 빠질 수 있는 반면 유전알고리즘은 교차 및 돌연변이 과정을 통해 보다 더 나은 세대로 진화해 전역 최적해에 도달할 수 있고, 이러한 특성 때문에 본 논문에서는 유전알고리즘으로 신경망의 구조와 가중치를 최적화하는 방법을 택했습니다.")

유전 알고리즘과 신경망 결합 시 중요한 문제는 신경망 구조를 염색체로 어떻게 표현하느냐입니다. **직접 표현(Direct Encoding)**은 노드나 가중치를 직접 염색체로 표현하는 방식이고, **간접 표현(Indirect Encoding)**은 값이 만들어지는 규칙을 염색체로 표현하는 방식입니다.

("유전알고리즘에서 중요한 것은 염색체를 어떻게 표현하는지, 적합도 함수를 어떻게 정의하는지에 따라서 성능이 결정되는데 이 논문에서는 가지치기를 하나 안하냐를 이진 리스트로 구현해 가장 효율적인 0과 1의 조합을 찾아내는 알고리즘을 제안했습니다.")

3. NNPGA 알고리즘

```


P개의 초기 해집단을 생성한다.;
P의 해들의 품질을 평가한다.;
repeat {
    P에서 두 개의 해  $p_1, p_2$  선택한다.;
    offspring = crossover( $p_1, p_2$ );
    // 부모 해로부터 교차와 변이를 통해
    mutation(offspring);           // 자식 해를 만든다.
    부모 염색체의 구조로부터 가중치를 상속한다.;
    자식 염색체로 표현된 신경망 구조 훈련.;
    자식 해의 품질을 평가한다.;
    P내의 해중 자식 해와 비교 품질이 좋지 않을 해를
    대치한다.;
} until (종료 조건);
P내에서 가장 우수한 해 C를 선택한다. ;
선택된 C 염색체로 표현된 신경망 구조를 평가한다.;

```

표현 방식

신경망의 입력층과 은닉층 노드의 제거 여부를 '0'(제거) 또는 '1'(유지)로 표현하여, 전체 염색체는 입력층과 은닉층 노드 수를 합한 길이의 비트열로 구성됩니다.

("먼저 노드의 제거 여부를 0과 1로 표현한다고 정의하고 0과 1로 이루어진 임의의 염색체를 생성합니다.")



○ 제거되지 않은 노드

⊙ 제거된 노드

염색체:

1	0	1	0	1	0	0	1
← 입력층 →				← 은닉층 →			

초기 해집단

모든 비트를 1로 시작한 후 원하는 가지치기 비율에 따라 임의의 위치에서 특정 개수의 비트를 0으로 변경합니다.

"현재는 입력층이 4개, 은닉층이 4개로 이루어진 구조에서 원하는 가지치기 비율에 따라 노드를 제거한 후에 그에 맞게"

염색체를 0과 1로 표현합니다."

적합도 평가 및 선택

검증 집합에 대한 RMSE(Root Mean Square Error) 값을 기반으로 적합도를 평가하며, 선택 연산에는 순위 기반 룰렛 휠 방법을 사용합니다.

$$p_i = \frac{1}{1 + e}, \quad i = 1, \dots, N$$
$$e = \frac{1}{n} \sum_{i=1}^n \sqrt{\frac{1}{m} \sum_{j=1}^m (y_j^i - t_j^i)^2}$$

"만들어진 염색체에 대해 적합도 평가를 하는데 현재는 **RMSE(Root Mean Square Error)**값에 1을 더한 값의 역수를 적합도 함수로 나타냈습니다. 이것은 **RMSE**값이 작을 수록 모델의 오차가 작을 수록 적합도 값은 커지기에 다음 세대에 **RMSE**값이 작은 즉 오차가 적은 염색체를 넘기도록 유도하는 메커니즘입니다. 여기서 저희가 흔히 신경망에서 사용하는 **MSE**를 사용하지 않고 루트를 씌운 이유는 현재 **RMSE**가 학습에 쓰이는게 아니라 오로지 오류값을 해석하는데에만 쓰였기에 실제 오차의 크기를 보려고 루트를 사용한 것 같습니다. 선택 연산자는 순위 기반 룰렛 휠 방법으로 적합도가 높은 유전자가 유리하게 선택되도록 설정했습니다."

교차와 돌연변이

선택된 부모 염색체는 교차와 돌연변이 연산을 통해 자식 해를 생성합니다. 교차와 돌연변이 후 목표 가지치기 비율이 유지되도록 비트를 조정합니다.


"교차는 3점 교차, 돌연변이는 각 비트에 대해 임의의 수를 생성하고 그 수와 미리 설정한 임계값과 비교해 0은 1로, 1은 0으로 바꾸는 방법을 택했습니다."

가중치 상속과 신경망 재훈련

자식 염색체의 가중치는 부모로부터 상속받으며, 이는 다음 네 가지 경우로 나뉩니다:

1. 부모 중 하나에만 가중치가 존재하면 해당 가중치 상속
2. 부모 모두 가중치가 존재하면 평균 값 상속
3. 부모 모두 가중치가 없으면 임의 값 상속

"앞서 선택, 교차, 돌연변이를 통해 신경망의 구조를 물려받았으면 이제 가중치를 상속받아야 합니다. 최대한 부모에게 가중치를 상속받기 위해 다음과 같이 행간하면 부모의 가중치를 물려받자는 매커니즘을 구현했습니다. 부모에게 가중치를 상속받는 것은 이미 적합도 계산을 통해 어느정도 검증된 신경망의 가중치이기에 의미있는 시작과 더불어 빠르고 안정적인 학습이 가능하기 때문에 충분히 근거있는 상속과정이라고 생각합니다."



자식 신경망의 가중치 계산을 해보면 일단 부모에게 받은 구조에 맞게 가중치를 설정하면 됩니다. 첫번째 간선(w_{11})에는 0.2와 0.3의 평균 0.25를 건네주고, 두번째 간선(w_{13})은 P_2 에만 존재하기에 그대로 가져오고 3번째 간선(w_{41}), 4번째 간선(w_{42})은 부모 모두 가중치가 없기에 임의 값을 주었습니다.

이 가중치 상속 과정은 오류 역전파의 지역 최적해 문제 극복에 도움이 됩니다.

대치 및 종료

자식 해의 품질이 부모보다 좋으면 부모를 대치하고, 그렇지 않으면 해집단 내 가장 낮은 품질의 해를 대치합니다. 유전 알고리즘은 정해진 세대 수에 도달하면 종료됩니다.

"이 알고리즘의 종료는 자식 유전자의 품질, 적합도 값이 부모보다 좋으면 대치하고 아니면 자식 집단 내 가장 낮은 품질의 해로 대치하고, 정해진 세대 수에 도달하면 종료됩니다."

4. 실험 결과 및 토론

UCI Machine Learning Repository의 다양한 분류 문제 데이터를 사용하여 실험했으며, 입력 데이터는 선형 함수로 정규화했습니다. 실험 설계에는 10-겹 교차검증 구조를 사용하여 과적합을 방지했습니다.

"실험은 UCI 머신러닝 레포지토리 내 13가지 다양한 분류 문제 데이터를 사용했고, 입력 데이터를 일정한 범위의 값으로 정규화해 데이터의 크기값 차이가 성능을 떨어뜨리지 않도록 하였고 10겹 교차검증을 통해 모델의 일반화 성능을 올려서 과적합을 방지했습니다."

Table 2. Accuracy according to the node pruning rate.

(단위 %)

Data set	가지치기 대상	4%	8%	10%	15%	20%	25%	30%	35%	40%	45%	50%
(1)	I+H	91.29±3.55	<u>92.74±4.40</u>	90.97±5.87	91.77±2.55	90.97±3.32	90.48±4.70	90.97±4.74	90.65±3.37	87.42±3.37	90.00±5.34	90.81±3.54
	I	92.74±4.46	<u>92.90±3.69</u>	91.94±3.61	92.36±2.48	92.10±5.02	92.10±3.13	90.00±3.13	90.65±3.04	90.00±3.66	90.81±2.89	90.48±2.55
	H	<u>96.94±1.83</u>	95.65±2.05	96.77±1.25	95.97±2.31	94.52±2.72	95.48±2.36	94.19±3.32	92.74±3.77	93.39±4.70	93.23±4.88	92.36±3.80
(2)	I+H	73.30±4.67	73.60±3.64	72.70±3.23	73.10±4.44	74.40±2.24	<u>74.40±2.24</u>	73.00±3.66	74.10±3.11	73.50±4.36	73.00±3.07	74.00±5.10
	I	72.60±4.61	73.90±2.26	71.70±3.13	74.30±2.83	72.30±3.98	73.90±4.32	73.50±5.50	75.20±3.54	71.00±3.10	<u>74.90±3.67</u>	74.70±2.24
	H	73.20±5.36	73.70±3.74	72.30±2.79	75.00±3.07	73.70±5.53	73.50±4.25	73.60±4.98	74.50±4.88	74.40±5.71	73.80±6.67	72.70±4.52
(3)	I+H	65.24±11.48	70.00±11.2	64.76±14.0	62.38±13.5	64.29±8.58	62.86±12.38	64.29±10.05	60.00±9.57	64.76±11.9	62.38±15.42	59.52±16.39
	I	60.95±10.39	63.81±10.26	62.38±10.31	62.38±9.39	57.14±12.95	60.95±13.93	61.43±10.31	57.62±13.21	<u>64.29±12.09</u>	56.19±13.09	59.05±13.33
	H	62.38±13.38	63.33±11.28	59.52±7.45	63.33±9.05	<u>64.29±8.04</u>	62.38±10.95	60.48±8.26	58.57±13.97	59.05±13.33	61.90±10.65	59.52±12.64
(4)	I+H	81.48±5.74	82.96±6.02	81.85±4.52	82.96±3.39	80.37±6.21	85.19±3.31	80.74±2.77	82.22±6.15	83.33±5.80	84.07±5.51	81.11±5.84
	I	78.89±8.77	80.74±9.19	80.00±8.80	81.48±8.11	80.74±7.55	<u>82.22±7.55</u>	81.85±8.02	80.37±8.45	80.00±8.64	78.89±6.64	80.00±9.40
	H	80.37±5.51	80.37±5.25	81.48±6.41	78.52±4.63	80.00±6.46	81.11±6.07	81.48±5.97	83.33±6.03	82.96±4.44	<u>83.70±6.67</u>	82.96±6.87
(5)	I+H	89.43±4.44	88.57±6.13	89.14±6.98	90.57±4.79	90.00±4.65	89.71±4.08	91.14±3.25	90.57±3.84	90.29±4.46	90.29±4.98	90.57±3.39
	I	91.14±6.57	90.00±3.89	90.57±5.72	89.71±4.28	90.86±3.79	89.14±3.33	88.86±4.32	88.00±9.88	89.14±6.98	<u>90.71±4.13</u>	89.43±6.65
	H	88.86±5.64	87.43±5.14	88.00±5.08	<u>86.86±4.28</u>	87.14±5.61	87.71±4.79	87.14±7.69	87.71±6.77	86.86±6.29	86.86±6.41	87.71±5.27
(6)	I+H	96.67±4.47	94.67±7.18	96.00±4.42	96.67±4.47	<u>97.33±4.42</u>	91.33±9.91	94.67±10.24	95.33±4.27	89.33±9.52	92.00±10.24	91.33±9.33
	I	96.00±3.27	96.00±4.42	<u>97.33±4.27</u>	95.33±4.27	93.33±6.67	96.67±4.47	93.33±11.93	86.67±16.06	92.00±11.08	92.00±8.33	92.67±8.14
	H	97.33±4.42	97.33±4.42	97.33±4.22	96.67±4.47	92.67±11.72	96.67±4.47	96.67±4.47	92.00±13.60	96.67±4.47	98.00±5.27	96.00±4.42
(7)	I+H	<u>77.50±6.40</u>	77.24±7.18	76.84±7.21	77.11±6.42	75.53±6.04	77.11±6.82	76.58±6.93	75.00±7.04	75.39±5.68	73.68±7.58	75.92±5.20
	I	77.63±3.53	75.92±4.16	76.05±4.19	76.45±4.01	76.71±3.86	77.76±2.85	76.97±4.33	75.53±3.18	76.05±3.42	74.08±5.61	76.45±2.91
	H	76.45±4.22	76.58±4.43	76.97±4.09	76.97±4.37	76.58±4.07	76.45±4.26	<u>76.97±4.00</u>	75.79±5.10	76.58±4.59	76.71±4.48	76.45±4.30
(8)	I+H	99.44±0.34	99.57±0.54	99.48±0.47	99.44±0.51	99.44±0.51	99.39±0.401	99.39±0.44	99.48±0.32	99.31±0.48	99.39±0.35	99.35±0.48
	I	99.44±0.48	99.44±0.48	99.39±0.48	99.48±0.47	99.39±0.48	99.44±0.48	99.48±0.48	99.48±0.47	99.38±0.51	<u>99.44±0.48</u>	99.31±0.48
	H	99.39±0.44	99.39±0.44	99.39±0.44	99.44±0.48	99.39±0.44	<u>99.48±0.47</u>	99.38±0.32	99.35±0.40	99.38±0.32	99.38±0.47	99.32±0.47
(9)	I+H	78.50±7.43	81.00±5.83	82.00±6.78	78.50±7.09	80.00±9.49	91.50±7.76	81.00±8.00	79.50±11.06	78.00±9.00	80.00±5.48	81.00±4.90
	I	79.00±8.00	80.00±8.37	78.50±9.23	79.50±9.60	82.50±11.24	79.00±7.00	<u>84.50±9.07</u>	83.00±8.72	82.50±7.50	78.50±12.66	79.50±8.79
	H	83.50±5.94	86.00±7.35	85.50±7.57	84.50±6.50	<u>85.00±7.07</u>	84.00±7.35	81.00±9.43	82.00±10.30	82.00±9.80	83.50±8.08	83.00±6.78
(10)	I+H	81.31±4.16	82.62±5.93	81.00±4.84	<u>85.36±4.33</u>	82.38±4.96	82.38±3.98	83.45±3.30	80.71±4.29	79.88±4.72	79.57±5.63	78.69±3.71
	I	<u>86.07±1.61</u>	85.24±3.07	84.88±4.02	84.64±4.14	83.45±4.00	83.57±3.83	81.07±3.78	83.10±5.13	81.67±2.73	79.88±5.82	80.95±4.39
	H	84.17±3.20	85.83±3.34	85.95±2.31	84.52±2.87	86.07±3.37	85.71±2.82	84.64±2.94	84.40±2.84	85.12±3.38	84.52±2.06	84.42±3.06
(11)	I+H	<u>89.09±4.04</u>	87.88±4.38	87.58±4.56	86.77±1.72	85.05±2.92	81.72±3.45	81.73±4.77	76.67±4.81	78.79±3.10	70.10±4.59	77.27±3.73
	I	<u>90.30±2.12</u>	88.79±2.61	89.49±2.93	88.89±2.02	88.48±3.76	85.05±3.31	86.77±3.87	84.24±3.39	82.83±4.69	81.01±3.16	80.30±4.55
	H	90.71±2.70	89.29±3.10	89.39±3.48	89.29±3.00	90.00±3.76	87.78±3.18	87.47±3.17	84.85±4.24	82.93±6.43	85.05±3.93	80.30±3.07
(12)	I+H	83.88±1.20	83.82±1.87	84.40±1.50	83.34±1.74	84.66±1.76	84.78±2.17	84.32±1.65	<u>84.88±1.64</u>	84.54±1.58	83.96±1.31	83.20±1.34
	I	84.00±2.03	84.92±1.84	84.40±1.71	84.48±2.35	84.50±2.26	84.38±2.70	84.02±2.77	83.06±2.14	82.88±3.26	83.16±1.63	82.04±2.84
	H	84.24±1.35	84.00±1.07	84.02±1.82	84.62±1.53	83.82±0.79	84.14±1.17	83.96±1.63	84.02±1.47	84.74±1.53	<u>84.82±1.80</u>	83.02±1.63
(13)	I+H	95.00±6.71	96.00±6.63	94.00±8.00	<u>97.00±6.40</u>	95.00±6.71	94.00±8.00	96.00±6.63	94.00±9.17	92.00±8.72	94.00±10.30	92.00±8.72
	I	96.00±4.90	97.00±4.58	97.00±4.58	<u>97.00±4.58</u>	95.00±6.71	94.00±4.90	94.00±6.63	96.00±4.90	96.00±6.63	95.00±6.71	94.00±4.90
	H	96.00±6.63	96.00±6.63	96.00±6.63	97.00±4.58	97.00±4.58	96.00±6.63	96.00±6.63	96.00±6.63	94.00±8.00	95.00±6.71	96.00±6.63

* I(Input Layer): 입력 노드, H(Hidden Layer): 은닉 노드, I+H(Input+Hidden Layer): 입력+은닉 노드

실험 결과, 입력층과 은닉층을 동시에 가지치기했을 때 각각 가지치기하는 방법보다 우수한 성능을 보였습니다. 데이터셋별로 차이는 있으나, 평균적으로 8%~25%의 가지치기 비율에서 가장 좋은 성능을 보였습니다.

"실험 결과 신경망 성능의 정확도 평균과 표준편차가 입력층과 은닉층을 동시에 가지치기 했을 때 따로 최적화했을 경우보다 5개 데이터에 대해 우수한 성능을 보였고 나머지 데이터에 대해서도 성능이 많이 뒤편어지지 않음을 알 수 있었고 평균적으로 8~25%정도 노드를 제거했을 때 좋은 성능을 보였습니다. 이를 통해 신경망의 구조가 단순해져 조금의 성능 저하가 있을지라도 소요되는 시간과 계산 비용을 크게 줄일 수 있는 이점이 있다는 것을 확인했습니다."

Table 3. Comparison of the proposed NNPGA and others four algorithms.

(단위 %)

Data set	NNPGA	NNPCv	C5.0	M5'	N2C2S
balance-scale	92.74±4.40	95.41±0.90(○)	77.60±1.00(●)	86.40±0.70(●)	92.30±0.80(○)
german	74.40±2.24	73.10±1.20(○)	71.20±1.00(●)	72.90±0.70(○)	70.10±1.60(●)
glass	70.00±11.28	64.90±2.30(●)	67.50±2.60(○)	70.50±2.80(○)	65.50±3.00(●)
heart-statlog	85.19±3.31	78.15±2.80(●)	78.70±1.40(●)	82.20±1.00(●)	77.50±1.00(●)
ionosphere	91.14±3.25	90.58±1.40(○)	88.90±1.60(●)	89.70±1.20(○)	89.50±2.20(○)
iris	97.33±4.42	96.67±1.00(○)	94.50±0.70(●)	94.70±0.70(●)	96.60±0.60(○)
pima	77.50±3.40	75.49±1.10(●)	74.50±1.20(●)	76.20±0.80(○)	76.00±0.80(○)
segment	99.57±0.54	96.97±0.30(●)	96.80±0.20(●)	97.00±0.20(●)	95.10±0.40(●)
sonar	82.00±6.78	78.65±2.30(●)	74.70±2.80(●)	78.50±3.40(●)	76.50±1.50(●)
vehicle	85.36±4.33	77.78±1.20(●)	72.90±1.20(●)	76.50±1.30(●)	84.20±0.70(○)
vowel	89.09±4.04	86.07±1.10(●)	79.80±1.30(●)	81.70±1.10(●)	88.80±1.40(○)
waveform-noise	84.88±1.64	83.20±0.80(●)	75.40±0.50(●)	82.00±0.20(●)	85.60±0.20(○)
zoo	97.00±6.40	94.00±2.50(●)	91.80±1.10(●)	92.10±1.30(●)	94.30±1.40(●)

※ NNPCv, C5.0, M5', N2C2S 데이터는 [27-30] 참고 자료

다른 알고리즘(NNPCv, C5.0, M5', N2C2S)과의 통계적 비교에서도 NNPGA 방법이 평균적으로 더 우수한 성능을 보였습니다.

"앞서 실험진행한 NNPGA에서의 최고 성능값과 동일한 데이터셋으로 실험한 다른 가지치기, 구조 증가 알고리즘과 통계적으로 비교했을때도 평균적인 성능 면에서 NNPGA가 좋은 결과를 보였습니다."

5. 결론

본 논문에서 제안한 NNPGA는 신경망의 입력층과 은닉층 노드를 동시에 가지치기하고 가중치를 상속받는 방법으로, 기존 방법보다 우수한 성능의 신경망 구조를 찾을 수 있었습니다.

실험 결과 8%~25% 정도의 가지치기에서 최적의 성능을 보였으며, 이는 신경망 계산량을 약 20% 감소시켜 처리 속도 개선에 효과적입니다. 향후 연구에서는 최적의 가지치기 비율을 자동으로 결정하는 방법 개발이 필요합니다.

"본 논문에서 제안한 NNPGA는 신경망의 입력층과 은닉층을 동시에 최적화하고 가중치 상속을 통해 기존 방법보다 우수한 성능의 신경망을 쉽고 빠르게 찾을 수 있었고 향후 연구에서는 최적의 가지치기 비율을 자동으로 결정하는 방법을 개발한 다고 합니다."

이상으로 GA를 이용한 신경망 구조 최적화 논문 발표를 마치겠습니다. 질문"